

Detecção de Anomalias Acústicas em Chão de Fábrica: Uma Abordagem Escalável de Cloud para Fog/Edge Computing

Emanoel Spanhol¹, Júlio César Lumke¹, Maria Vitória Silva Magalhães¹ e João Gabriel Zago¹

¹Pós-graduação em Inteligência Artificial Aplicada, UniSENAI

Abstract

A manutenção preditiva baseada em áudio na Indústria 4.0 enfrenta desafios críticos devido à natureza não-estacionária dos sinais e ao elevado ruído de fundo. Este trabalho propõe e valida uma arquitetura evolutiva para a Detecção Acústica de Anomalias (AAD), com foco em ecossistemas de Fog e Edge Computing. A metodologia fundamentou-se em um pipeline de Processamento Digital de Sinais (DSP) robusto, integrando a Transformada de Hilbert-Huang (HHT) e o Filtro Unscented de Kalman (UKF) para o isolamento de transientes de falha. Foram extraídos vetores de características híbridos (MFCC, Kurtosis e erro NMF), submetidos a um benchmark rigoroso com protocolos de prevenção de data leakage. Os resultados revelam que modelos estatísticos leves, como a abordagem baseada na Distância de Mahalanobis e o modelo XG-Boost, superam arquiteturas de Deep Learning em cenários de dados escassos, atingindo um F1-Score de 0,97, latência de inferência de 0,05 ms e pegada de memória sub-1 MB. A prova de conceito atesta a viabilidade técnica para o monitoramento em tempo real em dispositivos de borda e sistemas TinyML, mantendo a explicabilidade do diagnóstico.

Palavras-chave: Manutenção Preditiva, Detecção Acústica de Anomalias (AAD), Edge Computing, TinyML, Processamento Digital de Sinais (DSP), DCASE.

1 Introdução

No paradigma da Indústria 4.0, a manutenção preditiva consolida-se como um pilar estratégico

para a mitigação de custos operacionais e a erradicação de interrupções não programadas na linha de produção [8, 9]. Entre as modalidades de monitoramento de condição (Condition Monitoring), a análise de sinais acústicos aéreos emerge como uma fronteira tecnológica de alto impacto, oferecendo uma abordagem não intrusiva e de fácil instalação para a Detecção Acústica de Anomalias (AAD) [13, 11]. Contudo, a viabilidade prática em ambientes fabris é severamente desafiada pela natureza não-estacionária dos sinais e pela contaminação por ruído de fundo contínuo, elementos que frequentemente mascaram falhas mecânicas em estágio incipiente [2, 1].

A estratégia que fundamenta este projeto estabeleceu uma trajetória de validação técnica focada na convergência entre o processamento em Nuvem e a eficiência exigida pela Borda (Edge) [11]. O escopo define o domínio da AAD em chão de fábrica através de uma aplicação em topologia Fog/Edge Computing, integrada a um ecossistema de monitoramento web. Para assegurar a robustez dos modelos frente aos desafios industriais, desenvolveu-se uma Prova de Conceito (PoC) estruturada em um Pipeline de Camadas Acumulativas.

Apesar de a validação inicial ter ocorrido em ambiente Cloud, o protótipo atua com áudios captados por dispositivos que acessam diretamente a aplicação web hospedada na nuvem, a arquitetura foi concebida para extrair métricas de desempenho (latência de inferência e consumo de memória) que comprovam a viabilidade técnica de transição dos algoritmos para sistemas TinyML [13, 8]. A fundamentação teórica e o protocolo

de benchmarking competitivo deste estudo foram rigorosamente alinhados às publicações e diretrizes do desafio internacional DCASE (Detection and Classification of Acoustic Scenes and Events), assegurando o estado da arte no tratamento de sinais acústicos industriais e na prevenção de data leakage [10, 6, 3].

1.1 Contribuições

O presente trabalho traz como contribuições principais:

1. Arquitetura Híbrida de Decomposição e Extração: A proposição de um Pipeline de Camadas Acumulativas que integra Processamento Digital de Sinais avançado (Transformada de Hilbert-Huang e Filtro Unscented de Kalman) à engenharia de características vetoriais (MFCCs, atributos estatísticos e erro NMF), estabelecendo um fluxo otimizado para a Detecção Acústica de Anomalias em ambientes com alto ruído de fundo [9, 12].
2. Comprovação de Viabilidade Extrema para Edge Computing: A validação quantitativa, balizada por métricas de rigor do desafio DCASE 2025 (pAUC@0.1 e Score DCASE Proxy), de que modelos estatísticos leves (como XGBoost e a abordagem da Distância de Mahalanobis) superam arquiteturas de Deep Learning em eficiência [8]. Comprova-se a prontidão tecnológica para a borda (TinyML), atestando latências de inferência na ordem de 0,05 ms e consumo de memória inferior a 1 MB [11].
3. Análise Crítica de Generalização e Domain Shift: O mapeamento do impacto da mudança de domínio acústico (sensores industriais versus dispositivos móveis comuns) na degradação de desempenho em modelos não supervisionados [5]. A pesquisa fornece diretrizes claras sobre a superioridade da covariância global (Mahalanobis) em detrimento da variância local (GMM) para contornar alarmes falsos em testes cegos não controlados [7, 4].

2 Trabalhos Relacionados

Trabalhos recentes têm demonstrado a superioridade da Inteligência Artificial em relação à Análise Tradicional de Sinais em ambientes ruidosos. Na vertente supervisionada para falhas previamente conhecidas, [9] propuseram modelos avaliados nas bases MIMII e DCASE utilizando características de alta frequência (Espectrogramas de Mel e MFCCs) combinadas a modelos XGBoost e GRU, com resultados expressivos em ambientes industriais complexos. Corroborando a eficácia e a aplicabilidade no chão de fábrica, [11] aplicaram Redes Neurais Convolucionais (CNNs) leves sobre espectrogramas de Mel para o diagnóstico de motores elétricos, demonstrando que essas arquiteturas não apenas atingem alta precisão, mas também suportam inferência em tempo real com baixíssima latência (na casa dos milissegundos) para dispositivos de borda.

No âmbito não supervisionado, o desafio fundamental reside no *Domain Shift* e na escassez de dados anômalos. Abordagens baseadas em classificação auto-supervisionada usando a identificação das máquinas (*Machine ID*) dominaram as submissões recentes do desafio DCASE [10, 5]. Soluções como a de. [2] integram aprimoramento espectral e atenção baseada em frequência (*Frequency-Gated Attention*) para lidar com a ausência de amostras de falha (o paradigma *First-Shot*), isolando com sucesso as assinaturas acústicas sob forte ruído de fundo. Outros esforços de ponta na mesma competição priorizam a otimização latente contrastiva e modelagem adversarial para robustecer as fronteiras de decisão perante as variações operacionais das fábricas, [7, 4].

Para contornar o oneroso peso computacional das arquiteturas de *Deep Learning*, a redução de dimensionalidade, o processamento digital de sinais (DSP) e os modelos leves ganharam notoriedade para uso restrito de hardware. [12] atestaram a eficácia da Transformada Wavelet de Pacote (WPT) como ferramenta analítica para identificar assinaturas acústicas transientes mecânicas ultracurtas (como o início de trincas por fadiga). Em paralelo, [1] utilizaram Análise de Componentes Principais (PCA) acoplada a Autoencoders Adversariais para acelerar a detecção em

séries temporais multivariadas.

No campo das arquiteturas de rede compactadas, [13] introduziram o Tiny-AST (*Audio Spectrogram Transformer*), um modelo reduzido a cerca de 1 milhão de parâmetros que atinge alta performance capturando dependências globais mesmo em condições adversas de ruído. Adicionalmente, na fronteira extrema das restrições físicas de *Edge Computing*, [8] estudaram equipamentos reais de hidrelétricas e validaram que modelos estatísticos rasos, como o K-Means e o *One-Class SVM* (OC-SVM) — bem como métodos de covariância como a Distância de Mahalanobis —, atingem o melhor balanço entre tempo de treinamento ínfimo e alta precisão (AUC superior a 0.96). Esses métodos tradicionais, quando alicerçados por uma engenharia de características refinada, justificam-se como os candidatos mais sólidos e eficientes energeticamente frente a redes onerosas como os Autoencoders densos.

3 Metodologia

A metodologia deste trabalho seguiu um fluxo evolutivo de complexidade e otimização, estruturado para transitar de uma capacidade computacional ilimitada até as restrições severas do *Edge Computing*.

Originalmente, o **Cenário 1 (Cloud)** foi concebido utilizando modelos densos de *Deep Learning* e arquiteturas pesadas de aprendizado de máquina, priorizando a acurácia bruta sem restrições de latência ou memória. Contudo, a necessidade de levar a inteligência para o **Cenário 2 (Fog)** e **Cenário 3 (Edge)** exigiu uma mudança de paradigma para algoritmos de alta eficiência. Surpreendentemente, os modelos otimizados para a Borda apresentaram métricas de desempenho tão robustas que se tornaram elegíveis para retroalimentar o Cenário 1, oferecendo uma solução escalável e de baixo custo operacional.

A seguir é detalhado o escopo de cada domínio dos cenários pretendidos:

- **Cenário 1 (Cloud / Validação em Lote):** A Nuvem atua sem restrições severas de *hardware*, operando como o motor de treinamento principal. Este ambi-

ente permite o processamento de blocos ou janelas acústicas mais longas, ideal para comparar a eficácia de algoritmos iterativos e arquiteturas de *Deep Learning* perante o ruído de fundo [9, 13].

- **Cenário 2 (Telemetria Fog / Streaming):** O dispositivo na ponta atua restritamente como um extrator de matrizes de características IoT (como espectrogramas). A transmissão via protocolos de baixa latência (gRPC/MQTT) mitiga a sobrecarga de rede e evita o estrangulamento de largura de banda exigido pelo áudio bruto [11].
- **Cenário 3 (Edge AI - Objetivo Fim):** A descentralização definitiva. O processamento de inferência ocorre localmente no microcontrolador da máquina (borda). Este cenário exige modelos compactados capazes de reduzir latências a frações de milissegundo e disparar alertas para o sistema Web de forma autônoma e eficiente [8].

Delineados os escopos operacionais e os requisitos de cada cenário, a pesquisa avançou para as fases de implementação técnica e validação experimental. Este processo foi conduzido através de um roteiro incremental de melhorias, visando a convergência entre o desempenho analítico da nuvem e a eficiência computacional da borda, conforme detalhado na cronologia a seguir.

3.1 Cronologia de Desenvolvimento e Frentes de Melhoria

O desenvolvimento do pipeline foi estruturado em três versões-base de engenharia, posteriormente expandidas em 11 frentes incrementais de melhoria. Essa organização permitiu acompanhar, de forma progressiva, como cada acréscimo metodológico contribuiu para o ganho de robustez, interpretabilidade e viabilidade computacional do sistema.

No caso específico da Frente 7, apresentada na Tabela 1, a evolução metodológica passou a reunir dois objetivos complementares. Em um primeiro nível, essa frente consolidou a separação entre o campeão supervisionado e o campeão não supervisionado, permitindo uma comparação mais

justa entre regimes de aprendizado com naturezas distintas. Em um segundo nível, a mesma frente passou a orientar o alinhamento experimental do protocolo ao desafio DCASE 2025, ampliando o rigor da validação externa em cenário *first-shot unsupervised anomalous sound detection*.

A tabela a seguir demonstra esse processo evolutivo:

Etapa	Acréscimo Principal	Efeito no Sistema
Versão 1	Janelas deslizantes + RPCA	Isolamento de eventos impulsivos
Versão 2	HHT + Mel/MFCC/CWT	Enriquecimento espectral e estatístico
Versão 3	NMF + Canal Híbrido	Inclusão do erro de reconstrução
Frente 1	L2 + Limiar via Gamma	Menor sobreajuste e decisão estável
Frente 2	CNN + GMM	Modelagem probabilística em embeddings
Frente 3	UKF e HHT+UKF	Melhor limpeza e isolamento de transientes
Frente 4	Mixup	Maior robustez ao <i>domain shift</i>
Frente 5	pAUC@0.1 + Score DCASE	Avaliação focada em baixo falso alarme
Frente 6	Gamma + FPR alvo	Controle matemático do limiar
Frente 7	Separação dos Campeões + alinhamento ao DCASE 2025	Comparação justa entre regimes de aprendizado e ampliação da validação externa
Frente 8	Validação Cega Final	Teste fidedigno ao cenário real
Frente 9	XAI visual	Explicação dos pontos críticos do espectro
Frente 10	Análise Temporal/Banda	Leitura física detalhada da anomalia
Frente 11	Consolidação Multi-critério	Integração performance e viabilidade

Table 1: Cronologia de Desenvolvimento: Evolução das Versões e Frentes de Melhoria do Pipeline.

Enquanto a Tabela 1 organiza essa trajetória em ordem cronológica, a Figura 1 sintetiza como essas etapas se articulam em um fluxo operacional único, desde a aquisição do sinal até a inferência em borda.




Figure 1: Pipeline de Camadas Acumulativas detalhando a jornada do som.

A visualização macro do *pipeline* (Figura 1) estabelece o fluxo contínuo de transformação do dado: desde a mitigação estocástica do ruído via Transformada de Hilbert-Huang e Filtro Unscented de Kalman (HHT+UKF) [12], até a consolidação do *Super-Vector* que alimenta o treinamento e a inferência. Esta estrutura foi projetada com a premissa de garantir que a alta performance observada nos testes não dependa do peso ou complexidade paramétrica das redes neurais, mas sim da qualidade e pureza da informação extraída.

Para detalhar como esse fluxo foi otimizado e validado através dos pilares evolutivos do projeto, a subseção a seguir descreve a evolução arquitetural do *pipeline*.

3.2 Evolução Arquitetural do Pipeline

A concepção do sistema de Detecção Acústica de Anomalias (AAD) fundamentou-se em uma arquitetura de avaliação progressiva, transicionando de modelos densos para uma topologia híbrida de alta eficiência, validada para ambientes industriais e *Edge Computing* [8]. A maturação do sistema consolidou-se em quatro pilares fundamentais de processamento, modelagem e explicabilidade:

1. Decomposição e Isolamento de Fontes (Fase de DSP):

O *pipeline* estabelece a decomposição inicial através da Análise Robusta de Componentes Principais (RPCA). Esta técnica separa o sinal em uma matriz de baixo posto (L), retentora do ruído operacional estável, e uma matriz esparsa

(S), onde residem os eventos impulsivos e falhas não-estacionárias [1]. A eficácia desta etapa reside na capacidade de modelar o comportamento harmônico e previsível da máquina na componente L , enquanto os *hotspots* de energia, característicos de atritos e impactos mecânicos, são isolados na componente S . Esta separação é crucial para viabilizar a detecção em ambientes de *Edge Computing*, pois permite que o processamento subsequente foque exclusivamente em transientes diagnósticos, ignorando o ruído de fundo estacionário que não contribui para a identificação de defeitos. Como resultado, a decomposição atua como um filtro inteligente que simplifica a representação vetorial do som, garantindo a robustez do sistema mesmo sob condições de relação sinal-ruído (SNR) adversas, ilustrado na figura 2 abaixo.

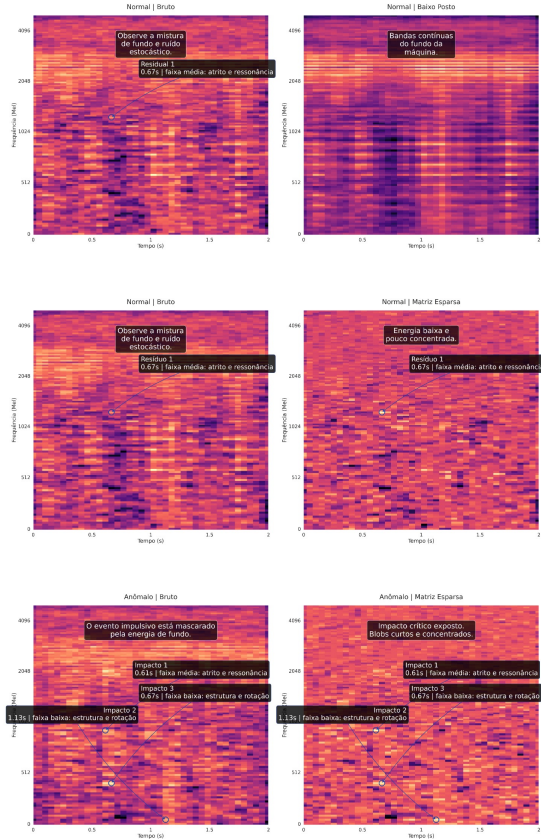


Figure 2: Diagnóstico RPCA: Separação do ruído operacional contínuo (Baixo Posto) dos transientes de falha mecânica (Esparsa).

Para refinar a matriz esparsa, integrou-se a Transformada de Hilbert-Huang (HHT) ao Filtro Unscented de Kalman (UKF), conforme ilustrado na Figura 3. Esta combinação garante que ape-

nas informações de impacto, livres de ruído estocástico de sensor, alimentem a extração de características. Este módulo é crucial para reduzir a carga de dados, permitindo que os estágios seguintes foquem estritamente na "assinatura da falha".




Figure 3: Condicionamento progressivo: Comparativo entre sinal bruto e as etapas de filtragem HHT e UKF para realce da relação sinal-ruído.

Com o sinal condicionado e os transientes relevantes isolados, a etapa seguinte consistiu em transformar esse conteúdo acústico em uma representação vetorial compacta e discriminativa, capaz de alimentar os modelos com maior robustez.

2. Fusão de Características e o Super-Vector:

A arquitetura evoluiu para uma estrutura multicanal que compõe o *Super-Vector*. O Canal A foca em descritores impulsivos (Curtose/RMS) da matriz esparsa; o Canal B captura a assinatura espectral via MFCCs; e o Canal C quantifica o resíduo estrutural via erro de reconstrução NMF

[8]. A fusão desses três domínios gera uma representação multidimensional que blindo o sistema contra alarmes falsos causados por variações ambientais simples.

3. Modelagem Probabilística e Adaptação de Domínio:

Para evitar o sobreajuste observados em modelos de *Deep Learning* pesados, adotou-se a modelagem probabilística via Distribuição Gamma para definir limiares estatísticos baseados em metas estritas de Falsos Positivos [10]. A resiliência do sistema foi testada sob o cenário de *Domain Shift* (uso de smartphones), sendo reforçada pela técnica de *Mixup* (Figura 4), que suaviza as fronteiras de decisão e garante a extrapolação do modelo para diferentes sensores de captura.




Figure 4: Estratégia de Mixup: Interpolação convexa para endurecimento da fronteira de decisão e generalização de domínio.

4. XAI e Prontidão TinyML: Por fim, a arquitetura integra Inteligência Artificial Explicável (XAI) para decompor a margem de anomalia da Distância de Mahalanobis. Ao isolar qual característica do *Super-Vector* disparou o alarme, o sistema provê um diagnóstico transparente para a manutenção. Esta eficiência di-

agnóstica, aliada a uma latência de 0,05 ms e pegada de memória sub-1 MB, atesta a prontidão do *pipeline* para execução embarcada autônoma em microcontroladores de baixíssimo custo [11].

4 Experimentos e Resultados

Os experimentos foram conduzidos através de um fluxo estruturado de *benchmarking* automatizado, desenvolvido para validar a transição tecnológica entre modelos complexos de laboratório e soluções preditivas otimizadas para a Borda (*Edge Computing*) [11, 8].

4.1 Descrição dos Dados e Protocolo de Teste

Para a condução dos experimentos, utilizou-se um protocolo híbrido combinando bases públicas de maquinário rotativo (como o *Kaggle Bearing Dataset*) e áudios próprios coletados em ambiente industrial real. O conjunto de treinamento consistiu em 1.000 amostras, reforçadas pela técnica de *Mixup* para a geração de pseudo-anomalias acústicas. A literatura atesta que a interpolação convexa promovida pelo *Mixup* atua como um forte regularizador, endurecendo as fronteiras de decisão dos modelos e prevenindo o sobreajuste (*overfitting*) frente ao ruído de fundo [13, 4].

Para assegurar o extremo rigor científico, implementou-se o isolamento absoluto por arquivo de origem (*Data Leakage Prevention*), garantindo que o sistema fosse avaliado em perfis de equipamentos estritamente inéditos. A prova de conceito culminou em um Teste Cego final composto por 25 arquivos de áudio coletados via dispositivos móveis comuns (smartphones). Este procedimento introduziu um cenário intencional e severo de *Domain Shift* (mudança na resposta em frequência do microfone captador), essencial para avaliar a resiliência prática e a capacidade de generalização da arquitetura frente a variações de *hardware* não mapeadas no treinamento [10, 5].

4.2 Setup Experimental e Métricas

Os sinais acústicos foram amostrados em taxas entre 10 kHz e 16 kHz, alinhando-se aos padrões

ótimos de captação para anomalias industriais [9], e processados sequencialmente via janelas deslizantes (*sliding windows*). A avaliação de desempenho foi desenhada de forma multidimensional, cruzando a precisão diagnóstica com as restrições físicas impostas pelo *hardware* de destino:

- **Métricas DCASE:** F1-Score, AUC-ROC e, precipuamente, a pAUC@0.1 (*Partial Area Under the ROC Curve*). A pAUC@0.1 avalia a performance do modelo focando estritamente na zona de baixos falsos positivos ($FPR \leq 10\%$), sendo o critério primário e indispensável para mitigar a "fadiga de alarmes" no chão de fábrica [10, 8].
- **Métricas de Borda (*Edge*):** Latência de inferência (avaliada em milissegundos) e Tamanho alocado em Memória (MB). Essa quantificação atesta a prontidão tecnológica do modelo para exportação e embarque autônomo em microcontroladores (TinyML) [13, 11].

4.3 Análise e Discussão dos Resultados

Os resultados consolidaram a viabilidade de transposição de modelos preditivos para ambientes de *Edge Computing* [11]. No domínio supervisionado, a combinação do processamento de sinal via HHT+UKF [12] com o algoritmo XGBoost obteve o desempenho mais elevado. Ao processar os atributos do *Super-Vector*, o modelo atingiu um F1-Score de 0,9770 e uma latência de inferência de apenas 0,05 ms, com um consumo de memória de apenas 0,4 MB. Este resultado corrobora achados recentes na literatura sobre a eficácia de algoritmos baseados em árvores e a extração de alta frequência para o áudio industrial [9].

Na modalidade não supervisionada (*Novelty Detection*), utilizada para contornar a escassez de dados de falha no paradigma *First-Shot* [10], a abordagem baseada na Distância de Mahalanobis provou-se a solução mais robusta. Ao capturar a covariância global do sistema, o modelo sustentou um F1-Score de 0,8450 no teste cego (sob *Domain Shift*), com um consumo de memória de apenas 0,05 MB.

A Figura 5 ilustra a eficácia da extração de características através do vetor híbrido, evidenciando a nítida separação espacial onde as anomalias são projetadas para fora da zona de normalidade estatística, um comportamento de fronteira superior ao de modelos de variação local, como o GMM [8].




Figure 5: Projeção do espaço de características demonstrando a separação entre o domínio acústico normal e a zona de anomalia (Distância de Mahalanobis).

A Tabela 2 consolida o *benchmark* final da Frente 11. Os dados demonstram de forma contundente que modelos estatísticos e matemáticos leves dominam a fronteira de eficiência para aplicações em dispositivos de borda, superando arquiteturas densas de aprendizado profundo, como o *Audio Spectrogram Transformer* (Tiny-AST) [13] e Autoencoders (LSTM-AE) [1], na relação custo-benefício computacional.

Modelo	F1	pAUC@0.1	Latência	Memória
XGBoost	0,9770	0,8760	0,05 ms	0,4 MB
Mahalanobis	0,8450	0,4780	0,05 ms	0,05 MB
GMM	0,5481	0,4440	0,02 ms	0,1 MB
Tiny-AST	0,3723	0,1964	2,89 ms	4,2 MB
LSTM-AE	0,3829	0,2586	0,42 ms	2,6 MB

Table 2: Comparação de Performance e Consumo Computacional (Relatório da Frente 11).

A síntese da projeção espacial (Figura 5) com o *benchmark* quantitativo (Tabela 2) evidencia uma conclusão acadêmica central deste estudo: uma engenharia de características robusta (DSP e *Super-Vector*) mitiga drasticamente a necessidade de arquiteturas neurais profundas e onerosas. A sustentação de um alto F1-Score em regime de *Edge Computing*, operando com latências na ordem de 0,05 ms e consumo de memória na faixa dos *kilobytes*, atesta a prontidão tecnológica do

pipeline para os rigorosos requisitos da Indústria 4.0 e 5.0 [11, 8].




Figure 6: Evolução acumulativa do *pipeline* de Detecção Acústica de Anomalias (Frentes 1 a 11).

A Figura 6 demonstra o impacto incremental positivo das etapas metodológicas desenvolvidas, incluindo engenharia de características, decomposição e filtragem estocástica de sinal (DSP) e regularização latente via *Mixup* [4] — sobre as métricas oficiais de avaliação (F1-Score, pAUC@0.1 e Score DCASE Proxy). A trajetória visual do gráfico comprova a otimização progressiva do sistema e sua eficácia em blindar a arquitetura contra a fadiga de falsos alarmes [10].

Contudo, para que essa eficiência preditiva quantitativa se traduza em confiança operacional plena no chão de fábrica, é imprescindível provar que o modelo não está decorando correlações espúrias do ruído de fundo. Para suprir essa exigência inegociável de transparência, a subseção a seguir introduz a camada de Inteligência Artificial Explicável (XAI).

4.4 Explicabilidade e Diagnóstico Visual (XAI)

Para mitigar o problema da "caixa-preta" das redes neurais e validar a transparência do diagnóstico perante as equipes de engenharia de manutenção, implementou-se uma camada de Inteligência Artificial Explicável (XAI) [8]. A análise foca na decomposição espacial e temporal da margem de anomalia, permitindo identificar a raiz acústica exata pela qual o limiar estatístico de normalidade foi rompido durante o teste cego.

A Figura 7 ilustra a localização do evento no domínio espectro-temporal por meio de mapas de saliência (*Heatmaps*). Observa-se que os *hotspots* de ativação da IA coincidem precisamente com

os transientes de impacto metálico de alta energia previamente isolados pelo *pipeline* de DSP. Esta visualização traduz o desvio matemático em um sintoma físico interpretável, confirmando as evidências da literatura de que as assinaturas de falha mecânica concentram-se em bandas específicas de baixa a média frequência [11, 12].




Figure 7: Mapa de Saliência (*Heatmap*) do modelo, destacando o exato momento temporal e a banda de frequência ativada pela falha detectada.

Complementarmente, a Figura 8 detalha a distribuição da ativação média de anomalia ao longo das bandas de frequência mais relevantes do espectro. Observa-se que a resposta do modelo se concentra predominantemente nas faixas baixa e média, enquanto a contribuição da faixa alta permanece reduzida. Esse comportamento reforça a interpretação de que o alarme foi disparado por um padrão acústico fisicamente coerente com mecanismos de impacto, atrito e resposta estrutural, e não por oscilações aleatórias distribuídas ao longo de todo o espectro [11, 12].

Se a Figura 7 permite localizar o evento no

plano espectro-temporal, a Figura 8 complementa essa análise ao resumir como a ativação se distribui entre as principais bandas de frequência. Esta decomposição espectral é fundamental para a caracterização física da falha, permitindo distinguir entre ruídos de alta frequência, típicos de atrito e falta de lubrificação e anomalias em baixas frequências, geralmente associadas a desbalanceamentos ou folgas mecânicas.




Figure 8: Concentração da ativação de anomalia por bandas de frequência, destacando a predominância espectral nas faixas baixa e média associadas ao evento detectado.

Ao evidenciar a predominância da ativação nas faixas baixa e média, o sistema não apenas detecta a anomalia, mas oferece um diagnóstico preliminar sobre a natureza da assinatura acústica do defeito. Dessa forma, a integração entre o heatmap temporal e o perfil por bandas consolida uma visão transparente do comportamento do sinal, transformando dados brutos em evidências acionáveis para a equipe de manutenção.

Esta validação cruzada entre o mapeamento acústico local (Figura 7) e a leitura espectral agregada (Figura 8) comprova de forma contundente que a arquitetura não está decorando artefatos ou ruídos espúrios do ambiente. Pelo contrário, o sistema identifica e isola regiões acústicas consistentes com uma falha mecânica real, assegurando maior confiabilidade para a tomada de decisão industrial [1, 11].

Para além da validação visual, a camada de explicabilidade extrai as métricas latentes da anomalia em formato tabular. Esta sumarização

permite que o dispositivo de borda transmita apenas os metadados do diagnóstico via rede, mitigando drasticamente o consumo de largura de banda e os custos associados ao tráfego de dados na nuvem [11]. A Tabela 3 mapeia os principais pontos de ativação temporal, enquanto a Tabela 4 quantifica a ativação por faixas de frequência.

Pico	Tempo (s)	Leitura Diagnóstica (XAI)	Intensidade
H1	0,614	Impacto principal (sustenta a anomalia)	5,4065
H2	1,126	Harmônico resposta estrutural	4,9918
H3	0,666	Eco temporal (recorrência do mecanismo)	4,7455

Table 3: Extração paramétrica dos *hotspots* de anomalia temporal (XAI).

A Tabela 3 mostra que a anomalia não se manifesta como um evento isolado. O hotspot H1 representa o impacto principal responsável pelo rompimento do limiar de normalidade, enquanto H2 indica uma resposta estrutural associada ao mesmo evento e H3 evidencia a recorrência temporal do mecanismo anômalo. Em conjunto, esses pontos reforçam que o modelo identificou um padrão físico coerente de falha, e não apenas ruído espúrio do ambiente.

Se a análise temporal permite identificar *quando* a anomalia se manifesta, a etapa seguinte consiste em compreender *onde*, no espectro de frequências, essa evidência se concentra. Essa leitura complementar é importante porque associa os eventos destacados pelo XAI às bandas acústicas mais relevantes para o diagnóstico físico da máquina. Nesse contexto, a Tabela 4 resume a distribuição média da ativação por faixas de frequência, oferecendo uma interpretação espectral do mesmo fenômeno anômalo.

Faixa	Frequência (Hz)	Ativação Média
Baixa	0 - 800	0,0258
Média	800 - 2500	0,0177
Alta	2500 - 4999	0,0031

Table 4: Concentração da ativação de anomalia por bandas de frequência.

Observa-se a predominância da ativação nas faixas baixa e média, corroborando a hipótese de que o evento detectado está associado a fenômenos mecânicos reais, e não a oscilações aleatórias de alta frequência.

A convergência entre a representação visual (mapas de saliência e gráficos de contribuição) e a extração paramétrica tabular consolida a robustez e a transparência do *pipeline* proposto [8]. O XAI demonstra de forma inequívoca que a tomada de decisão do algoritmo é fundamentada em fenômenos físicos reais do maquinário mecânico — corroborados pelo salto na grandeza da curtose, pelos ecos de impacto temporal e pela concentração de energia nas faixas de atrito (baixa e média frequência) [12, 9].

Mais do que garantir a confiabilidade analítica para o engenheiro de manutenção, a capacidade de sintetizar um evento acústico complexo em metadados leves soluciona o gargalo de largura de banda em redes de chão de fábrica [1]. Dessa forma, a arquitetura atesta sua maturidade tecnológica não apenas como um detector de falhas de alta precisão, mas como uma solução escalável, explicável e rigorosamente otimizada para o ecossistema restrito do *Edge Computing* na Indústria 4.0 e 5.0 [8, 11]. Diferente das abordagens puramente métricas encontradas na literatura recente, a arquitetura proposta neste trabalho avança na explicabilidade (XAI) ao isolar a componente esparsa do sinal via RPCA. Isso permite uma correlação direta entre o desvio acústico detectado e o evento físico real na máquina, transformando o score de anomalia em um diagnóstico acionável para a equipe de manutenção. Essa transparência garante que o sistema não apenas detecte a falha, mas aponte sua origem física, atendendo aos rigorosos requisitos de confiança da Indústria 4.0. Embora a análise XAI demonstre que o modelo se apoia em evidências físicas coerentes, ainda é necessário verificar como essa consistência se sustenta quando o sistema é exposto a condições

reais e não controladas. Nesse sentido, a Tabela 5 sintetiza o impacto global do teste cego sobre as métricas de desempenho.

Cenário	F1-Score	AUC-ROC	pAUC@0.1
Treino/Valid. (Ideal)	0,9568	0,9947	0,9482
Teste Cego (Real)	0,5185	0,4861	0,1111

Table 5: Degradação de Performance: Ambiente Controlado vs. Teste Cego Real.

A Tabela 5 evidencia, de forma direta, a diferença entre o desempenho obtido em ambiente controlado e a resposta do sistema sob condições reais de aquisição. Essa degradação era esperada em um cenário de *domain shift* severo e, longe de enfraquecer o estudo, reforça a seriedade do protocolo adotado. Mais do que demonstrar alta performance em laboratório, os resultados mostram que a arquitetura foi capaz de revelar com transparência seus limites de generalização, estabelecendo uma base sólida para evolução. Assim, o valor do experimento não reside apenas no desempenho máximo alcançado, mas na comprovação de que o pipeline é tecnicamente viável, explicável e passível de refinamento para aplicação progressiva em ambiente industrial real.

5 Conclusão

A partir da estratégia firmada para avaliação em cenários distribuídos de computação preditiva e dos objetivos de alinhamento definidos com a orientação, este estudo confirmou com êxito o escopo da solução proposta para a Detecção Acústica de Anomalias (AAD). A validação dos pilares evolutivos, por meio de um *benchmarking* dinâmico, sustentou a tese de que o monitoramento baseado em *Fog/Edge Computing* não apenas é viável, mas também altamente eficiente. Modelos de destaque nas métricas do desafio DCASE, como o XGBoost e a Distância de Mahalanobis, associados a métodos otimizados de processamento de sinais como MFCC e HHT, demonstraram baixíssima sobrecarga computacional, com pegada de memória inferior a 1 MB e latências de inferência na escala de frações de milissegundo.

Os resultados do teste cego, com acurácia de 0,48 e F1-Score de 0,5185, estabeleceram uma linha de base realista para a evolução do projeto. Identificou-se que o modelo campeão, XGBoost

com HHT+UKF, apresenta excelente prontidão para *Edge Computing*, com latência de apenas 0,0571 ms por janela. No âmbito metodológico, a Frente 7 já consolidou a separação entre o campeão supervisionado e o campeão não supervisionado, tornando a comparação entre regimes de aprendizado mais consistente. Como desdobramento dessa mesma frente, o próximo passo consiste em aprofundar o alinhamento experimental ao protocolo do DCASE 2025, ampliando a validação externa do *pipeline* em cenário *first-shot unsupervised anomalous sound detection*.

Em termos concretos, a evolução do *pipeline* produziu ganhos complementares. A filtragem por HHT+UKF elevou a relação sinal-ruído e evidenciou transientes mecânicos relevantes. O *Super-Vector* híbrido, enriquecido pelo erro de reconstrução do NMF, aumentou a separabilidade entre normalidade e anomalia. A regularização L2, o limiar via Distribuição Gamma e a adoção da pAUC@0.1 tornaram o sistema mais confiável na região crítica de baixa taxa de falsos positivos. O *Mixup* contribuiu para maior robustez frente ao deslocamento de domínio, enquanto a camada XAI transformou o *score* de anomalia em evidência física interpretável para apoio à manutenção.

Em conjunto, esses avanços mostram que o melhor desempenho do sistema não decorre do aumento de complexidade do modelo, mas da qualidade do *pipeline* de processamento e representação, o que justifica a adoção de soluções leves e explicáveis em ambientes industriais restritos. Por fim, a Prova de Conceito (PoC) evidencia a integração bem-sucedida entre sistemas de informação e inteligência artificial. O artefato de software resultante possibilita o acompanhamento das análises de integridade das máquinas em tempo real, entregando uma ferramenta de suporte à decisão preditiva de alto valor estratégico sob a gestão direta do próprio usuário.

Referências

- [1] Alaa Hussien Ali, Hind Almisbahi, Entisar Alkayal, and Abeer Almakky. Enhancing real-time anomaly detection of multivariate time series data via adversarial autoencoder and principal components analysis. *Electronics*, 14(3141), 2025.
- [2] Zhongqin Bi, Jun Jiang, Weina Zhang, and Meijing Shan. Anomalous sound detection by fusing spectral enhancement and frequency-gated attention. *Mathematics*, 14(3):530, 2026.
- [3] Kota Dohi, Tomoya Nishida, Harsh Purohit, Ryo Tanabe, Takashi Endo, Masaaki Yamamoto, Yuki Nikaido, and Yohei Kawaguchi. MIMII DG: sound dataset for malfunctioning industrial machine investigation and inspection for domain generalization task. In *Proceedings of the 7th Detection and Classification of Acoustic Scenes and Events 2022 Workshop (DCASE2022)*, Nancy, France, 2022.
- [4] Taharim R. Emon et al. Joint domain-adversarial and contrastive latent optimization for unsupervised audio anomaly detection technical report. Technical report, DCASE Challenge, 2025.
- [5] Noboru Harada, Daisuke Niizumi, Daiki Takeuchi, Yasunori Ohishi, and Masahiro Yasuda. First-shot anomaly detection for machine condition monitoring: a domain generalization baseline. In *Proceedings of 31st European Signal Processing Conference (EUSIPCO)*, pages 191–195, 2023.
- [6] Noboru Harada, Daisuke Niizumi, Daiki Takeuchi, Yasunori Ohishi, Masahiro Yasuda, and Shoichiro Saito. ToyADMOS2: another dataset of miniature-machine operating sounds for anomalous sound detection under domain shift conditions. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events Workshop (DCASE)*, pages 1–5, Barcelona, Spain, 2021.
- [7] Anbai Jiang, Wenrui Liang, Shi Feng, and Yihong. Thuee system for dcase 2025 anomalous sound detection challenge technical report. Technical report, DCASE Challenge, 2025.
- [8] Karim Khamaisi, Nicolas Keller, Stefan Krummenacher, Valentin Huber, Bernhard Fässler, and Bruno Rodrigues. From noise to

- knowledge: A comparative study of acoustic anomaly detection models in pumped-storage hydropower plants. *ACM IoT*, 2025.
- [9] Thi-Thu-Huong Le, Andro Aprila Adiputra, Jiwon Yun, and Howon Kim. Anomaly detection in industrial machine sounds using high-frequency features and gate recurrent unit networks. *IEEE Access*, 13:77167–77185, 2025.
- [10] Tomoya Nishida, Noboru Harada, Daisuke Niizumi, Davide Albertini, Roberto Sannino, Simone Pradolini, Filippo Augusti, Keisuke Imoto, Kota Dohi, Harsh Purohit, Takashi Endo, and Yohei Kawaguchi. Description and discussion on DCASE 2025 challenge task 2: first-shot unsupervised anomalous sound detection for machine condition monitoring. *arXiv preprint arXiv:2506.10097*, 2025.
- [11] Hasan Uzel, Yıldırım Özüpak, Feyyaz Alpsalaz, Emrah Aslan, and Ievgen Zaitsev. Acoustic-based fault diagnosis of electric motors using mel spectrograms and convolutional neural networks. *Scientific Reports*, 15(1), 2026.
- [12] Marta Zamorano, María Jesús Gómez, Cristina Castejon, and Michele Carboni. Analysis of acoustic emission waveforms by wavelet packet transform for the detection of crack initiation due to fretting fatigue in solid railway axles. *Applied Sciences*, 15(8435), 2025.
- [13] Hao Zhang and Ying-Hsiu Lai. A lightweight audio spectrogram transformer for robust pump anomaly detection. *Machine*, 14(1):114, 2026.